

# Министерство науки и высшего образования Российской Федерации Федеральное государственное бюджетное образовательное учреждение высшего образования

# «Московский государственный технический университет имени Н.Э. Баумана (национальный исследовательский университет)»

(МГТУ им. Н.Э. Баумана)

Курс «Методы машинного обучения»

Отчет по лабораторной работе №3: «Обработка признаков (часть 2)»

Выполнила:

студентка группы ИУ5-24М

Мащенко Е. И.

Проверил:

Балашов А.М.

# Цель работы

Изучение продвинутых способов предварительной обработки данных для дальнейшего формирования моделей.

# Задание

- 1. Выбрать один или несколько наборов данных (датасетов) для решения следующих задач. Каждая задача может быть решена на отдельном датасете, или несколько задач могут быть решены на одном датасете.
- 2. Для выбранного датасета (датасетов) на основе материалов лекций решить следующие задачи:
- масштабирование признаков (не менее чем тремя способами);
- обработку выбросов для числовых признаков (по одному способу для удаления выбросов и для замены выбросов);
- обработку по крайней мере одного нестандартного признака (который не является числовым или категориальным);
- отбор признаков: один метод из группы методов фильтрации (filter methods), один метод из группы методов обертывания (wrapper methods), один метод из группы методов вложений (embedded methods).

# Выполнение работы

```
Лабораторная работа №3
 B [1]: | import numpy as np
             import pandas as pd
            import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
%matplotlib inline
sns.set(style="ticks")
from sklearn.impute import SimpleImputer
from sklearn.impute import MissingIndicator
import scip, state as ctati
             import scipy.stats as stats
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.preprocessing import MinMaxScaler
            from sklearn.preprocessing import RobustScaler
from sklearn.linear_model import LogisticRegression
from sklearn.svm import LinearSVC
 B [2]: M data = pd.read_csv("house_sales.csv")
 B [3]: ▶ data.head()
               ld MSSubClass MSZoning LotFrontage LotArea Street Alley LotShape LandContour Utilities ... PoolArea PoolQC Fence MiscFeature MiscVal
             0 1 60 RL 65.0 8450 Pave NaN Reg Lvl AllPub ... 0 NaN NaN
                                                                                                                            NaN
                                   RL
                                            80.0
                                                   9600 Pave NaN
            2 3
                      60 RL 68.0 11250 Pave NaN IR1 Lvi AllPub ... 0 NaN NaN
                                                                                                                             NaN
                                                                                                                                      0
             3 4
                          70
                                   RL
                                            60.0 9550 Pave NaN
                                                                        IR1
                                                                                    Lvl AllPub ...
                                                                                                             NaN NaN
                                                                                                                              NaN
                                                                                                                                       0
             4 5 60 RL 84.0 14260 Pave NaN IR1 Lvl AllPub ... 0 NaN NaN NaN 0
            5 rows × 81 columns
 B [4]: M data = data.drop('Id', 1) data.head()
               MSSubClass MSZoning LotFrontage LotArea Street Alley LotShape LandContour Utilities LotConfig ... PoolArea PoolQC Fence MiscFeature N
             0 60 RL 65.0 8450 Pave NaN Reg Lvl AllPub Inside ... 0 NaN NaN NaN
                       20
                                RL
                                          80.0
                                                9600 Pave NaN
                                                                     Reg
                                                                                  Lvl AllPub
                                                                                                 FR2
                                                                                                                   NaN
                                                                                                                         NaN
                                                                                                                                    NaN
                    60 RL 68.0 11250 Pave NaN IR1 Lvl AllPub Inside ...
                                         60.0
                                RL
                                                9550 Pave NaN
                                                                     IR1
                                                                                 Lvl AllPub
                                                                                                                   NaN NaN
                                                                                              Corner ...
                                                                                                              0
                                                                                                                                    NaN
             4 60 RL 84.0 14260 Pave NaN IR1 LvI AliPub FR2 ... 0 NaN NaN NaN
            5 rows × 80 columns
В [5]: ₩ # Удале
                                         процентом пропусков (более 25%)
           data.dropna(axis=1, thresh=1095)
                 MSSubClass MSZoning LotFrontage LotArea Street LotShape LandContour Utilities LotConfig LandSlope ... EnclosedPorch 3SsnPorch Screet
                     60 RL 65.0 8450 Pave
                                                                   Reg Lvl AllPub
                                                                                             Inside
                         20
                                                         Pave
                                                                               Lvl AllPub
                                                                                               FR2
                                  RL
                                            80.0
                                                   9600
                                                                   Reg
                                                                                                          Gtl ...
           2
                                RL
                                                                            Lvl AllPub
                                                                                                                       0
                                                                                                                                   0
                        60
                                         68.0 11250 Pave
                                                                  IR1
                                                                                             Inside
                                                                                                         Gtl ...
                                            60.0
                                                  9550
                                                                               Lvl AllPub
                                                                                                         Gtl ...
           4 60 RL 84.0 14260 Pave
                                                                         Lvl AllPub FR2
                                                                  IR1
                                                                                                        Gtl ... 0 0
                         60 RL 62.0 7917 Pave
                                                                         Lvl AllPub
                                  RL
                                                  13175 Pave
                                                                               Lvl AllPub
                                                                                                         Gtl ...
            1456
                         20
                                           85.0
                                                                   Rea
                                                                                             Inside
                                                                                                                          0
                        70 RL
                                                                                                                        0
                                        66.0 9042 Pave
            1457
                                                                             Lvl AllPub
                                                                                             Inside
                                                                                                         Gtl ...
                                                                                                                                   0
                                            68.0 9717 Pave
                                                                   Reg
                                                                               Lvl AllPub
                    20 RL 75.0 9937 Pave
            1459
                                                                  Reg
                                                                         Lvl AllPub
                                                                                             Inside
                                                                                                   Gtl ...
                                                                                                                   0 0
           1460 rows × 75 columns
           <
В [6]: ₩ # Заполним пр
           # SunonHow inpuryex (_peopleman and and and and defingute addef impute_na(df, variable, value):

df[variable].fillna(value, inplace=True)
impute_na(data, 'LotFrontage', data['LotFrontage'].mean())
B [7]: ▶ data.describe()
                 MSSubClass LotFrontage
  Out[7]:
                                          LotArea OverallQual OverallCond YearBuilt YearRemodAdd MasVnrArea BsmtFinSF1 BsmtFinSF2 ... Wood
            count 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 ... 1460.00000
            mean
                   56.897260 70.049958 10516.828082 6.099315 5.575342 1971.267808
                                                                                        1984.865753 103.685262 443.639726 46.549315 ...

        std
        42.300571
        22.024023
        9981.264932
        1.382997
        1.112799
        30.202904
        20.645407
        181.066207
        456.098091
        161.319273
        ...
        128

                                                       1.000000
                                                                  1.000000 1872.000000
                                                                                        1950.000000
                                                                                                     0.000000
                                                                                                                0.000000
                                                                                                                          0.000000 ...
              min
                    20.000000 21.000000
                                         1300.000000
            25% 20.000000 60.000000 7553.500000 5.000000 5.000000 1954.000000
                                                                                       1967.000000 0.000000 0.000000 0.000000 ...
                                                                 5.000000 1973.000000
                                         9478.500000
                                                       6.000000
                                                                                                     0.000000 383.500000
            75% 70.00000 79.00000 11601.500000 7.000000 6.00000 2000.000000 2004.000000 166.00000 712.250000 0.000000 ... 168
                   190.000000 313.000000 215245.000000 10.000000
                                                                 9.000000 2010.000000
                                                                                        2010.000000 1600.000000 5644.000000 1474.000000 ....
           8 rows × 37 columns
```

```
B [8]: ▶ def obj col(column):
                return column[1] == 'object'
           col_names = []
for col in list(filter(obj_col, list(zip(list(data.columns), list(data.dtypes))))):
    col_names.append(col[0])
           col_names.append('SalePrice')
 B [9]: ► X_ALL = data.drop(col_names, axis=1)
В [10]: 🔰 # Функция для восстановления датафрейма
            # на основе масштабированных данных
           def arr_to_df(arr_scaled):
               res = pd.DataFrame(arr_scaled, columns=X_ALL.columns)
                return res
В [11]: 🔰 # Разделим выборку на обучающую и тестовую
           X_train, X_test, y_train, y_test = train_test_split(X_ALL, data['SalePrice'],
                                                               test size=0.2
                                                              random_state=1)
           # Преобразуем массивы в DataFrame
X_train_df = arr_to_df(X_train)
X_test_df = arr_to_df(X_test)
           X_train_df.shape, X_test_df.shape
  Out[11]: ((1168, 36), (292, 36))
         StandardScaler
 В [12]: 🔰 # Обучаем StandardScaler на всей выборке и масштабируем
             cs11 = StandardScaler()
            data_cs11_scaled_temp = cs11.fit_transform(X_ALL)
# φορνωμογων DataFrame на основе массива
            data_cs11_scaled = arr_to_df(data_cs11_scaled_temp)
            data_cs11_scaled
   Out[12]:
                  MSSubClass LotFrontage LotArea OverallQual OverallQual VearBuilt YearRemodAdd MasVnrArea BsmtFinSF1 BsmtFinSF2 ... GarageArea V
               0 0.073375 -0.229372 -0.207142 0.651479 -0.517200 1.050994
                                                                                -0.872563
                              0.451936 -0.091886 -0.071836
                                                           2.179628 0.156734
                                                                                 -0.429577
                                                                                          -0.572835
                                                                                                     1.171992
                                                                                                               -0.288653 ...
                                                                                                                             -0.060731
               2 0.073375 -0.093110 0.073480 0.651479 -0.517200 0.984752
                                                                              0.309859 -0.456474 -0.096897 0.651479 -0.517200 -1.863632
                                                                                 -0.720298 -0.572835 -0.499274
                                                                                                               -0.288653 ... 0.790804
             1455 0.073375 -0.365633 -0.260560 -0.071836 -0.517200 0.918511 0.733308 -0.572835 -0.973018 -0.288653 ... -0.060731
             1456
                    -0.872563
                              0.679039 0.266407 -0.071836
                                                           0.381743 0.222975
                                                                                 0.151865 0.084610
                                                                                                     0.759659
                                                                                                                0.722112 ... 0.126420
                                                                                 1.024029 -0.572835 -0.369871 -0.288653 ... -1.033914
             1457
                    0.309859 -0.183951 -0.147810 0.651479 3.078570 -1.002492
                                                                                 0.539493 -0.572835
             1458
                    -0.872563 -0.093110 -0.080160 -0.795151
                                                           0.381743 -0.704406
                                                                                                     -0.865548
                                                                                                                6.092188 ... -1.090059
             1459
                    -0.962566 -0.572835 0.847389 1.509640 ... -0.921624
             1460 rows × 36 columns
 В [13]: 🕨 # Построение плотности распределения
            def draw_kde(col_list, df1, df2, label1, label2):
    fig, (ax1, ax2) = plt.subplots(
                    ncols=2, figsize=(12, 5))
                 # первый графин
                 ax1.set_title(label1)
                sns.kdeplot(data=df1[col list], ax=ax1)
                ax2.set title(label2)
                 sns.kdeplot(data=df2[col_list], ax=ax2)
                plt.show()
В [14]: № draw_kde(['LotFrontage', 'LotArea', 'OverallCond'], data, data_cs11_scaled, 'До масштабирования', 'После масштабирования')
                             До масштабирования
                                                                           После масштабирования
                                                             0.35

    LotFrontage

    LotFrontage

                                               LotArea
                                                                                              LotArea
                                                             0.30
              0.25
                                            — OverallCond
                                                                                          — OverallCond
                                                             0.25
              0.20
                                                             0.20
            0.15
                                                            0.15
              0.10
                                                             0.10
              0.05
                                                             0.05
```

0.00

0.00

50000

100000

150000

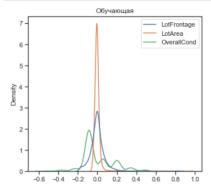
200000

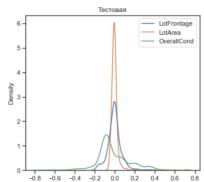
#### Масштабирование "Mean Normalisation"

```
B [15]: М # Разделим выборку на обучающую и тестовую
X_train, X_test, y_train, y_test = train_test_split(X_ALL, data['SalePrice'],
                                                                                                                                                  test size=0.2
                                                                                                                                                 random_state=1)
                             X_train_df = arr_to_df(X_train)
X_test_df = arr_to_df(X_test)
                             X_train_df.shape, X_test_df.shape
       Out[15]: ((1168, 36), (292, 36))
 B [16]: | class MeanNormalisation:
                                     def fit(self, param_df):
    self.means = X_train.mean(axis=0)
    maxs = X_train.max(axis=0)
    mins = X_train.min(axis=0)
                                               self.ranges = maxs - mins
                                      def transform(self, param_df):
    param_df_scaled = (param_df - self.means) / self.ranges
    return param_df_scaled
                                      def fit_transform(self, param_df):
    self.fit(param_df)
                                               return self.transform(param_df)
 B [17]: ► sc21 = MeanNormalisation()
                             data cs21 scaled = sc21.fit transform(X ALL)
                             data_cs21_scaled.describe()
       Out[17]:
                                                                                                                                                                         YearBuilt YearRemodAdd MasVnrArea BsmtFinSF1 BsmtFinSF2 ... Garage
                                           MSSubClass LotFrontage
                                                                                                   LotArea OverallQual OverallCond
                              count 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 ... 1460.000000 ... 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.000000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.0000 1460.00000 1460.0000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.0000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.00000 1460.0000 1460.0000 1460.00000 1460.00000 1460.00000 1460.00000 1460.000000
                                                 0.000962 -0.000452
                               mean
                                                                                               -0.000119
                                                                                                                       -0.003900
                                                                                                                                               -0.003058
                                                                                                                                                                       -0.003544
                                                                                                                                                                                                      -0.008644 -0.000898
                                                                                                                                                                                                                                                      -0.001612
                                                                                                                                                                                                                                                                               0.001276 ...
                                                                                                                                                                                                                                                                                                            -0.00
                                              0.109443 ... 0.15
                                  min
                                                -0.216081
                                                                        -0.168431
                                                                                                -0.043200
                                                                                                                        -0.570491
                                                                                                                                                -0.656678
                                                                                                                                                                         -0.722876
                                                                                                                                                                                                       -0.589740
                                                                                                                                                                                                                               -0.065702
                                                                                                                                                                                                                                                       -0.080216
                                                                                                                                                                                                                                                                               -0.030304 ... -0.33
                                 25%
                                                 -0.216081
                                                                        -0.034869
                                                                                               -0.013970 -0.126046
                                                                                                                                               -0.085250
                                                                                                                                                                         -0.128673
                                                                                                                                                                                                       -0.306407
                                                                                                                                                                                                                               -0.065702
                                                                                                                                                                                                                                                       -0.080216
                                                                                                                                                                                                                                                                               -0.030304 ...
                                 50%
                                                -0.039610
                                                                        -0.000452
                                                                                                -0.004973
                                                                                                                        -0.014935
                                                                                                                                                -0.085250
                                                                                                                                                                          0.009008
                                                                                                                                                                                                        0.143593
                                                                                                                                                                                                                               -0.065702
                                                                                                                                                                                                                                                       -0.012267
                                                                                                                                                                                                                                                                               -0.030304 ...
                                                                                                                                                                                                                                                                                                             0.004
                                                                                                                                                                                                       0.310260 0.038048 0.045980 -0.030304 ... 0.07
                                 75% 0.078037 0.030199 0.004951 0.096176 0.057608 0.204661
                                                                                                                                                                                                                                                                               0.969696 ...
                                                                                                                                                                          0.277124
                                 max
                                                0.783919
                                                                        0.831569
                                                                                                0.956800
                                                                                                                        0.429509
                                                                                                                                                0.486179
                                                                                                                                                                                                        0.410260
                                                                                                                                                                                                                               0.934298
                                                                                                                                                                                                                                                       0.919784
                                                                                                                                                                                                                                                                                                             0.66
                             8 rows × 36 columns
B [18]: N cs22 = MeanNormalisation()
cs22.fit(X_train)
data_cs22_scaled_train = cs22.transform(X_train)
data_cs22_scaled_test = cs22.transform(X_test)
 B [19]: ► data_cs22_scaled_train.describe()
                                            MSSubClass LotFrontage
                                                                                                        LotArea OverallQual OverallCond
                                                                                                                                                                                    YearBuilt YearRemodAdd MasVnrArea BsmtFinSF1 BsmtFinSF2 .

        count
        1.168000e+03
        1.168000e+03

                                                                                                                                                                                                                                                                                              -2.471387e-
18
                                              -1.672939e- 17 1.392531e-17 18 2.718526e-17 9.125121e-18 7.224054e-16 -1.502508e-15 2.584140e- 18 5.322987e-18
                              mean
                             std 2.475340e-01 7.707084e-02 4.616115e-02 1.522067e-01 1.587482e-01 2.195064e-01 3.431316e-01 1.112988e-01 8.212989e-02 1.098439e-01 ..
                                               -2.160808e-
                                                                        -1.684311e-
                                                                                                   -4.319969e-
                                                                                                                             -5.704909e-
                                                                                                                                                      -5.138209e-
                                                                                                                                                                                 -7.228757e-
                                                                                                                                                                                                                                          -6.570151e-
                                                                                                                                                                                                                                                                   -8.021550e-
                                                                                                                                                                                                                                                                                              -3.030380e-
                                 min
                                                                                                                                                                                                            -5 897403e-01
                                                                                                                                                                                                             -2.897403e-01
                                               -3.961019e-
                                                                         -4.518024e-
                                                                                                   -4.865072e-
03
                                                                                                                             -1.493531e-
02
                                                                                                                                                        -8.524951e-
02 1.625472e-02
                                                                                                                                                                                                                                          -6.570151e-
02
                                                                                                                                                                                                                                                                    -9.609550e-
                                                                                                                                                                                                                                                                                               -3.030380e-
02
                                 50%
                                                                                                                                                                                                            1.435930e-01
                                 75% 7.803687e-02 3.019903e-02 5.045185e-03 9.617580e-02 5.760763e-02 2.119069e-01 3.102597e-01 4.070474e-02 4.890392e-02
                                 max 7.839192e-01 8.315689e-01 9.568003e-01 4.295091e-01 4.861791e-01 2.771243e-01 4.102597e-01 9.342985e-01 9.197845e-01 9.696962e-01 .
                            8 rows × 36 columns
B [20]: M draw_kde(['LotFrontage', 'LotArea', 'OverallCond'], data, data_cs21_scaled, 'До масштабирования', 'После масштабирования')
                                   0.30
                                                                                                                LotArea
                                                                                                                                                                                                                            LotArea
                                   0.25
                                                                                                        OverallCond
                                                                                                                                                                                                                    OverallCond
                               0.15
                                   0.10
                                   0.05
                                                                                100000
                                                                                                  150000
                                                                                                                                                         -0.75 -0.50 -0.25 0.00 0.25 0.50 0.75 1.00
                                                                                                                   200000
```





## MinMax-масштабирование

```
B [22]: М # Обучаем StandardScaler на всей выборке и масштавируем
cs31 = MinMaxScaler()
data_cs31_scaled_temp = cs31.fit_transform(X_ALL)
# формируем DataFrame на основе массива
data_cs31_scaled = arr_to_df(data_cs31_scaled_temp)
data_cs31_scaled.describe()
```

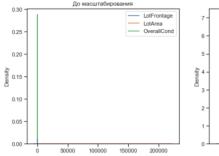
out[22]:		MSSubClass	LotFrontage	LotArea	OverallQual	OverallCond	YearBuilt	YearRemodAdd	MasVnrArea	BsmtFinSF1	BsmtFinSF2	 Garage.
	count	1460.000000	1460.000000	1460.000000	1460.000000	1460.000000	1460.000000	1460.000000	1452.000000	1460.000000	1460.000000	 1460.00
	mean	0.217043	0.167979	0.043080	0.566591	0.571918	0.719332	0.581096	0.064803	0.078604	0.031580	 0.33
	std	0.248827	0.075425	0.046653	0.153666	0.139100	0.218862	0.344090	0.113166	0.080811	0.109443	 0.15
	min	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	 0.00
	25%	0.000000	0.133562	0.029229	0.444444	0.500000	0.594203	0.283333	0.000000	0.000000	0.000000	 0.23
	50%	0.176471	0.167979	0.038227	0.55556	0.500000	0.731884	0.733333	0.000000	0.067948	0.000000	 0.33
	75%	0.294118	0.198630	0.048150	0.666667	0.625000	0.927536	0.900000	0.103750	0.126196	0.000000	 0.40
	max	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	 1.00

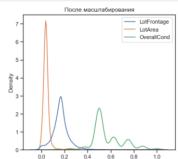
8 rows × 36 columns

```
B [23]: 

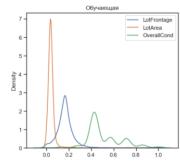
N cs32 = MinMaxScaler()
cs32.fit(X_train)
data_cs32_scaled_train_temp = cs32.transform(X_train)
data_cs32_scaled_test_temp = cs32.transform(X_test)
# dopxnupyen DataFrame na ocnobe maccuba
data_cs32_scaled_train = arr_to_df(data_cs32_scaled_train_temp)
data_cs32_scaled_test = arr_to_df(data_cs32_scaled_test_temp)
```

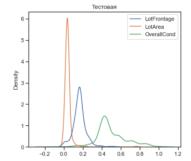
B [24]: N draw\_kde(['LotFrontage', 'LotArea', 'OverallCond'], data, data\_cs31\_scaled, 'До масштабирования', 'После масштабирования')



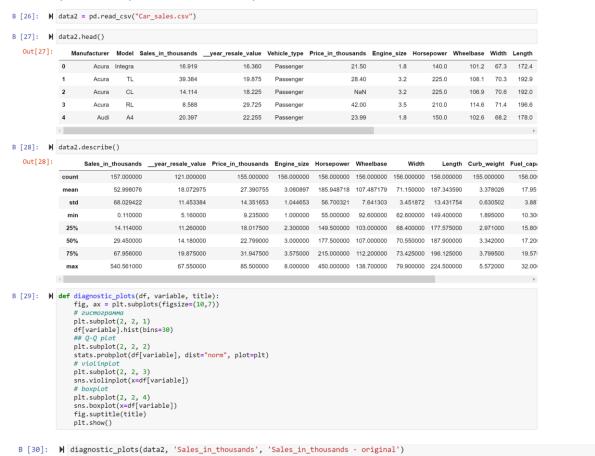


B [25]: 🔰 draw\_kde(['LotFrontage', 'LotArea', 'OverallCond'], data\_cs32\_scaled\_train, data\_cs32\_scaled\_test, 'Обучающая', 'Тестовая')

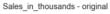


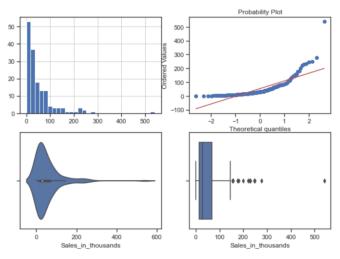


## Обработка выбросов для числовых признаков



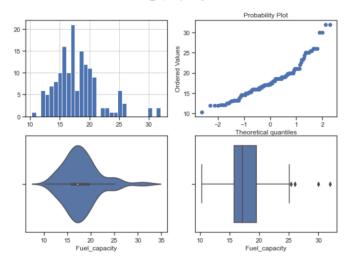
#### [50]. Watagnostie\_prots(data2, Sales\_in\_thousands, Sales\_in\_thousand





```
B [31]: M diagnostic_plots(data2, 'Fuel_capacity', 'Fuel_capacity - original')
```

Fuel\_capacity - original



```
B [32]: № # Тип вычисления верхней и нижней границы выбросов
from enum import Enum
class OutlierBoundaryType(Enum):
    SIGMA = 1
    QUANTILE = 2
    IRQ = 3
```

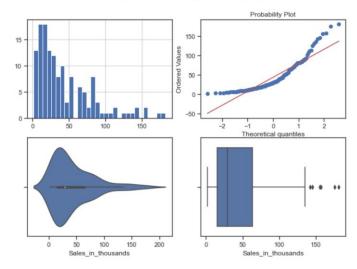
```
B [33]: 

# Функция бычисления верхней и нижней границы выбросов

def get_outlier_boundaries(df, col):
    lower_boundary = df[col].quantile(0.05)
    upper_boundary = df[col].quantile(0.05)
    return lower_boundary, upper_boundary
```

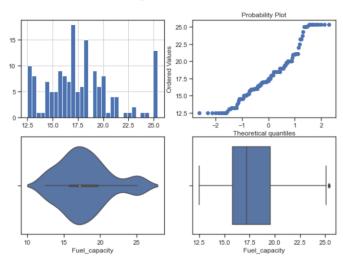
# Удаление выбросов (number\_of\_reviews)

Поле-Sales\_in\_thousands, метод-QUANTILE, строк-141



# Замена выбросов

Поле-Fuel\_capacity, метод-QUANTILE



## Обработка нестандартного признака

```
B [36]: ▶ data2.dtypes
   Out[36]: Manufacturer
                                                        object
                   Model
                                                       object
float64
                  Sales_in_thousands
_year_resale_value
Vehicle_type
Price_in_thousands
                                                      float64
                                                       object
float64
                   Engine_size
Horsepower
                                                       float64
                                                       float64
                                                      float64
float64
                   Wheelbase
                   Width
                   Length
                                                       float64
                  Curb_weight
Fuel_capacity
Fuel_efficiency
Latest_Launch
                                                       float64
                                                       float64
                                                       float64
                                                        object
                  Power_perf_factor
dtype: object
                                                      float64
```

В [37]: № # Сконбертируем дату и бремя в нужный формат data2["Latest\_Launch\_Date"] = data2.apply(lambda x: pd.to\_datetime(x["Latest\_Launch"], format='%m/%d/%Y'), axis=1)

B [38]: ▶ data2.head(5)

Out[38]:		Manufacturer	Model	Sales_in_thousands	year_resale_value	Vehicle_type	Price_in_thousands	Engine_size	Horsepower	Wheelbase	Width	Length
	0	Acura	Integra	16.919	16.360	Passenger	21.50	1.8	140.0	101.2	67.3	172.4
	1	Acura	TL	39.384	19.875	Passenger	28.40	3.2	225.0	108.1	70.3	192.9
	2	Acura	CL	14.114	18.225	Passenger	NaN	3.2	225.0	106.9	70.6	192.0
	3	Acura	RL	8.588	29.725	Passenger	42.00	3.5	210.0	114.6	71.4	196.6
	4	Audi	A4	20.397	22.255	Passenger	23.99	1.8	150.0	102.6	68.2	178.0
	c											>

```
B [39]: ► data2.dtypes
  Out[39]: Manufacturer
                                                  object
                                                 object
float64
              Model
              Sales_in_thousands
              __year_resale_value
Vehicle_type
                                                 float64
                                                  object
              Price_in_thousands
Engine_size
                                                 float64
float64
              Horsepower
Wheelbase
                                                 float64
                                                 float64
              Width
                                                  float64
              Length
Curb_weight
                                                 float64
                                                 float64
              Fuel_capacity
Fuel_efficiency
                                                 float64
                                                 float64
              Latest_Launch
                                                  object
              Power_perf_factor
Latest_Launch_Date
                                                 float64
                                         datetime64[ns]
              dtype: object
B [40]: М # День data2['Latest_Launch_Day'] = data2['Latest_Launch_Date'].dt.day
              data2['Latest_Launch_Month'] = data2['Latest_Launch_Date'].dt.month
              data2['Latest_Launch_Year'] = data2['Latest_Launch_Date'].dt.year
```

## Отбор признаков

## Метод фильтрации (Корреляция признаков)

```
B [41]: N sns.heatmap(data.corr(), annot=True, fmt='.3f')
                        Out[41]: <AxesSubplot:>
                                                                                                                                          MSSubClassi
LotArea
Lo
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                          - 0.8
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                       - 0.6
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                       - 0.4
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                       - 0.2
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                            -0.2
В [42]: 🔰 # Формирование DataFrame с сильными корреляциями
                                                                                                               # Формирование DataFrame с сильными корре
def make_corr_df(df):
    cr = data.corr()
    cr = cr.abs().unstack()
    cr = cr.sort_values(ascending=False)
    cr = cr[cr > 0.3]
    cr = cr[cr < 1]
    cr = pd.DataFrame(cr).reset_index()
    cr.columns = ['f1', 'f2', 'corr']
    return cr
                                                                                                                                                            return cr
```

```
В [43]: 🕨 # Обнаружение групп коррелирующих признаков
                            def corr_groups(cr):
    grouped_feature_list = []
    correlated_groups = []
                                    for feature in cr['f1'].unique():
    if feature not in grouped_feature_list:
        # HαχοδωΜ κορρεπυργοωμα πρυβακα
        correlated_block = cr[cr['f1'] == feature]
        cur_dups = list(correlated_block['f2'].unique()) + [feature]
        grouped_feature_list = grouped_feature_list + cur_dups
        correlated_groups.append(cur_dups)
                                     return correlated_groups
B [44]: ₩ # Группы коррелирующих признаков corr_groups(make_corr_df(data))
    'MasVnrArea',
'TotRmsAbvGrd',
                                 'Fireplaces',
'GarageCars'],
                               ['GrLivArea',
'TotRmsAbvGrd',
                                  'HalfBath',
'BedroomAbvGr',
                              'FullBath',
'SalePrice',
'MSSubClass',
'2ndFlrSF'],
['BsmtFullBath',
                                   'TotalBsmtSF',
                                  'BsmtUnfSF',
'1stFlrSF',
'SalePrice',
                                  'BsmtFinSF1<sup>'</sup>],
                               ['1stFlrSF',
'GrLivArea',
'TotalBsmtSF',
                                 'MSSubClass',
'SalePrice',
'GarageArea',
'TotRmsAbvGrd',
```

'LotArea',

#### Метод из группы методов вложений

```
B [45]: M data3 = pd.read_csv("WineQT.csv", sep=",")
B [46]: X3 ALL = data3.drop(['quality'], axis=1)
В [47]: 🕨 # Разделим выборку на обучающую и тестовую
              X3_train, X3_test, y3_train, y3_test = train_test_split(X3_ALL, data3['quality'],
                                                                           test size=0.2.
                                                                           random_state=1)
В [48]: 🔰 # Используем L1-регуляризацию
              e_lr1 = LogisticRegression(C=1000, solver='liblinear', penalty='l1', max_iter=500, random_state=1)
e_lr1.fit(X3_train, y3_train)
                             пы регрессии
              e lr1.coef
   -3.02935401e+00, -3.49793957e+00, 4.48070237e-03], [-1.70947991e-02, 3.42135554e+00, -1.21007833e-01,
                        8.32452278e-02, 3.20689559e+00, -1.25693925e-02, -5.18479271e+00,
                                                                1.03669460e-02,
                                                                 2.46658035e+00,
                                                                -4.73535890e-04],
                      9.88462824e-01, -2.04766665e-01, [-1.50633685e-01, 1.93721323e+00,
                                                                1.12321685e+00,
                         1.01141678e-02, 1.55206374e+00, 1.48826890e-02, 5.10001726e+00,
                                                                -1.74615115e-02,
                                                                -2.81228295e-02
                         -2.62509731e+00, -9.26899115e-01,
                                                                 5.26799951e-05],
                      [ 1.90322225e-01, -1.79843954e+00, -4.72955643e-02, 2.58455381e+00,
                                                                -2.04300613e+00.
                                                                 1.21352411e-02,
                       -7.83754176e-03, -2.99949432e+00, 8.78802257e-01, 2.38635326e-01,
                                                                 9.79232831e-01
                                                                 1.63131072e-04],
                       [-2.89452663e-02, -3.07001091e+00, 7.64831115e-02, -1.76133253e+01,
                                                                 1.47490514e+00,
                                                                 2.58137752e-02,
                        -2.04458316e-02, -3.51585085e+00, -1.28269840e+00, 2.73049298e+00, 8.81957513e-01, -5.47347256e-04],
                       [-5.95096357e-01, 3.04283371e+00, 3.41733495e+00, -1.83182731e-01, -3.51167880e+01, -2.83696795e-02,
                        -2.51328328e-02, 7.93053290e+00, -9.85694602e+00
                         3.86988223e+00, 1.26366792e+00, 6.15531404e-04]])
В [49]: 🕨 # Все признаки являются "хорошими"
              from sklearn.feature_selection import SelectFromModel
              sel_e_lr1 = SelectFromModel(e_lr1)
              sel_e_lr1.fit(X3_train, y3_train)
              sel_e_lr1.get_support()
  Out[49]: array([ True, True])
B [50]: ► e_lr2 = LinearSVC(C=0.01, penalty="11", max_iter=2000, dual=False)
              e_lr2.fit(X3_train, y3_train)
# Коэффициенты регрессии
              e_lr2.coef_
   Out[50]: array([[ 0.00000000e+00, 0.00000000e+00,
                                                                 0.00000000e+00,
                       0.00000000e+00, 0.00000000e+00,
-4.11584442e-03, 0.00000000e+00,
                                                                 0.00000000e+00.
                                                                 0.00000000e+00,
                         0.00000000e+00, -8.74407788e-02,
                                                                 2.16207334e-05],
                      [-3.25628793e-02,
                                            0.00000000e+00,
                                                                 0.00000000e+00,
                         0.00000000e+00,
                                            0.00000000e+00,
                                                                 0.00000000e+00.
                                            0.00000000e+00,
                        -1.53902483e-03,
                                                                 0.00000000e+00
                                            -5.09606676e-02,
                         0.00000000e+00,
                                                                -7.57523845e-05],
                      [ 5.38756260e-03, 0.000000000e+00,
                                            0.00000000e+00,
                                                                 0.00000000e+00.
                                            0.00000000e+00,
                                                                -1.01417935e-02,
                         9.74912863e-03, 0.00000000e+00, 0.00000000e+00, -1.39093107e-01,
                                                                 2.68698244e-01.
                                                                 6.67223898e-05],
                      [-3.23266765e-03,
-3.14247006e-03,
                                            0.00000000e+00,
                                                                0.00000000e+00,
8.03254900e-03,
                                            0.00000000e+00,
                       -6.31217465e-03,
                                            0.00000000e+00,
                                                                 0.00000000e+00
                         0.00000000e+00,
                                            0.00000000e+00,
                                                                 1.50706409e-051.
                      [-3.14854297e-03,
                                            0.00000000e+00,
                                                                 0.00000000e+00,
                         0.00000000e+00,
                                            0.00000000e+00.
                                                                 3.10839571e-03.
                        -4.09621571e-03,
                                            0.00000000e+00,
                                                                -2.53447375e-01,
                         0.00000000e+00,
                                            3.23459050e-02, -8.18767831e-05],
                                                                 0.00000000e+00,
                      [-3.58424690e-02,
                                            0.00000000e+00,
                       0.00000000e+00, 0.00000000e+00, -3.69131986e-03, 0.00000000e+00,
                                                                0.00000000e+00.
                                                                0.00000000e+00,
                         0.00000000e+00, -4.94273181e-02, -5.74232107e-05]])
B [51]: М #Признаки с флагом False д.б. исключены sel_e_lr2 = SelectFromModel(e_lr2)
              sel_e_lr2.fit(X3_train, y3_train)
              sel_e_lr2.get_support()
  Out[51]: array([ True, False, False, True, False, True, False, True, False, True])
```